MDPI

Article

Análisis exploratorio de la calidad del aire en València

Jose Luis, Marcos[1]

[1] Máster en Ciencia de Datos Universitat de València; correo@ejemplo.com

Simple Summary: Proyecto de la asignatura Análisis Exploratorio de Datos (AED) sobre la calidad del aire en Valencia.

Abstract: Resumen

Keywords: calidad del aire; contaminantes; NO2; PM10; O3; análisis exploratorio

Índice del proyecto

1. Introducción 2
2. Objetivo del proyecto 2
3. Preparación y acondicionamiento de datos 2
4. Distribución de los principales contaminantes entre las estaciones de medición 5
   4.1. Análisis de estadísticos 6
   4.2. Visualización de los contaminantes 7
5. Análisis temporal 9
   5.1. Serie diaria y estado de alarma 9
   5.2. Ciclo horario: laborables frente a fines de semana 10

Citation: Apellido, N. Análisis exploratorio de la calidad del aire en València. *Journal Not Specified* **2024**, *1*, 0. https://doi.org/

Received:
Revised:
Accepted:
Published:

Copyright: © 2026 by the author. Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

1. Introducción

Este proyecto aborda un problema real de análisis de datos ambientales dentro de la asignatura de *Análisis Exploratorio de Datos* (AED) del Máster en Ciencia de Datos de la UV. Para llevarlo a cabo, utilizamos el registro oficial ("*Datos horarios de calidad del aire desde 2016*") del portal de datos abiertos del Ayuntamiento de València, procesado bajo el nombre de *calidad_aire.csv*.

Sabiendo que la atmósfera funciona como un sistema dinámico donde las emisiones de origen antrópico y las variables meteorológicas condicionan la concentración de contaminantes, emplearemos el análisis exploratorio como herramienta para transformar los datos brutos en información interpretable, para así evaluar la calidad del aire en la ciudad de València.

2. Objetivo del proyecto

El objetivo de este proyecto es llevar a cabo un análisis exploratorio de datos de la calidad del aire en Valencia, focalizándonos en los contaminantes principales con mayor registro (NO_2, O_3, SO_2) y en las variables meteorológicas (temperatura, presión, radiación y humedad). Para ello, realizaremos un proceso de depuración, transformación (Data Wrangling) y visualización de datos en R, de tal manera que logremos caracterizar el comportamiento estadístico del sistema atmosférico.

Para guiar el análisis exploratorio y dar validez física a los resultados, el proyecto busca responder las siguientes preguntas de investigación:

- ¿Cómo se distribuyen los niveles de los principales contaminantes (NO_2, O_3, SO_2) entre las estaciones de medición de la ciudad?
- ¿Cómo evolucionan los contaminantes a lo largo del tiempo?,¿se observa estacionalidad?

3. Preparación y acondicionamiento de datos

3.0.1. Fuente de datos, importación y conversión:

El análisis parte del registro oficial "*Datos horarios de calidad del aire desde 2016*", obtenido del portal de datos abiertos del Ayuntamiento de Valencia. El formato elegido es CSV de tal manera que podamos representar los datos en una tabla, donde las columnas se separan punto y coma y las filas por saltos de línea. El archivo se procesa bajo el nombre de *calidad_aire.csv*.

Según la teoría tratada, datos recién importados se consideran *Raw Data* y contienen inconsistencias que impiden un análisis directo. Por ello, el proceso de acondicionamiento exige transformar el conjunto en un formato *Technically Correct Data*.

El primer paso es importarlos desde la carpeta *data* mediante una ruta relativa que evite dependencias absolutas del equipo:

```
#Cargamos la librería "readr"
library(readr)

#Importamos usando ruta relativa
datos <- read.csv("calidad_aire.csv", sep = ";", fileEncoding = "UTF-8")
```

Para estudiar la estructura inicial del conjunto de datos y verificar su volumen, ejecutamos las funciones de inspección básicas (*str()*, *head()*, *tail()* y *summary()*):

```
#Número de filas y columnas en total
dim(datos)

#Inspeccionamos estructura interna de las variables
str(datos)
```

```r
#Observamos la columna Fecha correctamente convertida a tipo POSIXct.

#Visualizamos primeras y últimas filas
head(datos)
tail(datos)

#Resumen estadística preliminar
summary(datos)

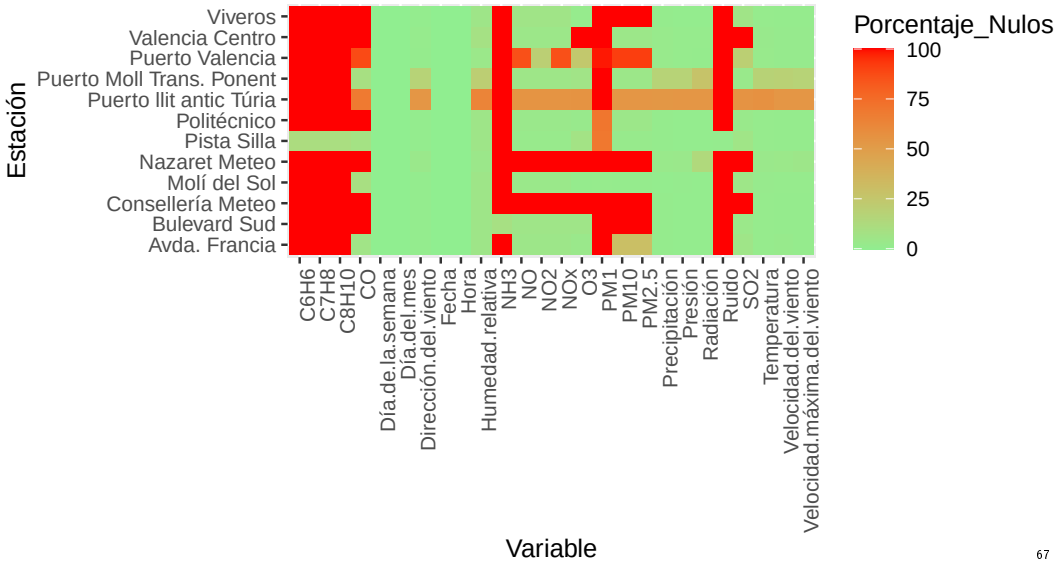
colnames(datos)
```

Al examinar los resultados de esta exploración inicial observamos que el conjunto cuenta con 449.026 observaciones (filas) y 27 variables (columnas):

- La columna "Fecha" se ha importado como texto plano (*chr*) e incluye una letra "T" intermedia (ej. 2020-01-01T00:00:00), lo que impide a R tratarla como una línea de tiempo real.
- Variables cualitativas como "Día.de.la.semana", "Hora" y "Estación" figuran como texto plano (*chr*), convertirlas a factores es indispensable para que R las trate como variables categóricas permitiendo así que los gráficos operen de manera eficiente posteriormente.
- En el *summary* observamos que las variables con mayor número de *NAs* son ("C6H6" con 402.660, "C7H8" con 402.240 y el "C8H10" con 402.087).Muy cerca se sitúan el "NH3" con 401.307 y la variable "Ruido" con 397.324.
- El *summary* también refleja una anomalía física puntual, la variable "Radiación" muestra un valor mínimo negativo imposible de -7.0, requiriendo una corrección.

```r
library(dplyr)
library(tidyr)
library(ggplot2)

# Visualizamos el porcentaje de NAs por estación y variable mediante un mapa de ca
datos %>%
  group_by(Estación) %>%                                    # nulos por estación
  summarise(across(everything(), ~ mean(is.na(.)) * 100)) %>%  # % de NAs por vari
  pivot_longer(-Estación, names_to = "Variable", values_to = "Porcentaje_Nulos") %
  ggplot(aes(Variable, Estación, fill = Porcentaje_Nulos)) +
  geom_tile() +                                             # mapa de calor
  scale_fill_gradient(low = "lightgreen", high = "red") +   # verde  a rojo
  theme(axis.text.x = element_text(angle = 90, hjust = 1))  # etiquetas X en verti
```



Una vez detectadas estas deficiencias en el formato bruto, aplicamos las herramientas de las librerías lubridate y dplyr para corregir los dos primeros puntos anteriores, corregir el formato de la columna "Fecha" y convertir "Día.de.la.semana", "Hora" y "Estación" a factor:

```
#Cargamos librerías
library(lubridate)
library(dplyr)

#Convertimos la columna Fecha a formato POSIXct
datos$Fecha <- as.POSIXct(datos$Fecha, format = "%Y-%m-%dT%H:%M:%S", tz = "UTC")

#Convertimos variables cualitativas a factores para facilitar el filtrado y agrupa
datos <- datos %>%
  mutate(
    Estación = as.factor(Estación),
    Día.de.la.semana = as.factor(Día.de.la.semana),
    Hora = as.factor(Hora))

#Verificamos las transformaciones
str(datos[c("Fecha", "Día.de.la.semana", "Hora", "Estación")])
```

3.0.2. Selección de variables y filtrado

Continuamos corrigiendo las observaciones anteriores. Recordamos que los contaminantes mencionados anteriormente como el benceno, tolueno y xileno, presentan pérdidas masivas de datos ($> 400.000 NAs$), esto valida la decisión de descartar las columnas prácticamente vacías ya que mantenerlas carece de rigor físico y entorpece el análisis exploratorio.

Sin embargo, los contaminantes principales ("NO2", "O3" y "SO2") y las variables meteorológicas ("Temperatura", "Humedad.Relativa", "Presión", "Precipitación") cuentan con una completitud altísima, registrando apenas entre 13,000 y 16,000 NAs. Por ello, empleamos paquete *dplyr*, concretamente aplicamos *select()* para conservar exclusivamente estas variables de interés de tal manera que la dimensión resultante será 449026x16:

```
# Seleccionamos las variables de interés y filtramos
datos_filtrados <- datos %>%
  select(
    Fecha, Hora, Día.de.la.semana, Estación,
```

```
    NO, NO2, NOx, O3, SO2, PM2.5, PM10,
    Temperatura, Humedad.relativa, Presión, Radiación, Precipitación
  ) %>%
  filter(!is.na(Fecha)) # Aseguramos coherencia temporal eliminando nulos críticos

# Verificamos las dimensiones resultantes del dataset depurado
dim(datos_filtrados)
```

3.0.3. Valores perdidos NAs e imputación:

Aunque hayamos seleccionado las variables de interés, el conjunto de datos aún presenta NAs en los contaminantes principales y meteorológicos, además de la anomalía física detectada en la radiación. Ambos deben resolverse antes de proceder con la visualización.

Por un lado, la "Radiación" no puede registrar valores negativos, para solucionar esta inconsistencia sin descartar toda la observación, empleamos la gramática de *dplyr*, concretamente *mutate* para reasignar dicho valor anómalo a NA:

```
#Convertimos en NA los valores negativos de Radiación
datos_filtrados <- datos_filtrados %>%
  mutate(Radiación = ifelse(Radiación < 0, NA, Radiación))
```

Por otro lado, es necesario cuantificar los NAs en las variables conservadas para decidir si aplicar una imputación o excluirlos con (na.rm = TRUE), evitando así sesgar los datos originales.

```
#Contabilizamos los NAs por columna
colSums(is.na(datos_filtrados))

dim(datos_filtrados)
```

El recuento revela que las columnas "Fecha", "Hora", "Día.de.la.semana" y "Estación" presentan completitud absoluta (0 NAs). Las variables meteorológicas muestran una alta completitud, destacando la "Presión" (13.753 NAs), la "Precipitación" (14.525 NAs), la "Radiación" (16.380 NAs) y la "Temperatura" (16.827 NAs).

Así mismo, los contaminantes principales (NO2, O3, SO2, y NOx) acumulan un volumen ligeramente alto de ausencias (oscilando entre 96.232 NAs en el NO2 y 124.888 NAs en el SO2), así como las columnas de partículas en suspensión (PM2.5 PM10) registrando el número de NAs más elevado, 226.614 y 226.609 respectivamente.

Descartamos la eliminación de filas, pues destruiría la continuidad de la serie temporal. También prescindimos de la imputación masiva mediante medias o medianas, ya que rellenar miles de huecos con un valor constante reduciría artificialmente la varianza y suavizaría los picos reales de contaminación.

Por tanto, se opta por preservar los NAs en el dataset y gestionarlos de forma local mediante el argumento *na.rm = TRUE*, operando así únicamente con los registros reales disponibles sin alterar la dinámica atmosférica.

Con un volumen final de 449.026 observaciones y 16 variables, el dataset queda estructurado en un formato sólido (*Technically Correct Data*) para iniciar la fase de Análisis Visual donde daremos respuesta a las preguntas de investigación planteadas.

4. Distribución de los principales contaminantes entre las estaciones de medición

Nos centramos ahora en dar respuesta a la primera pregunta formulada: ¿Cómo se distribuyen los niveles de NO_2 y O_3 entre las distintas estaciones de medición de la ciudad de Valencia?

4.1. Análisis de estadísticos

Para comenzar, podemos realizar un resumen estadístico de estos contaminantes, en función de cada una de las estaciones. Comenzamos analizando los estadísticos por estaciones correspondientes al dióxido de nitrógeno (NO_2):

```
estaciones_descartadas <- c("Consellería Meteo", "Nazaret Meteo",
                            "Valencia Centro")

resumen_estaciones_NO2 <- datos_filtrados %>%
  filter(!(Estación %in% estaciones_descartadas)) %>%
  group_by(Estación) %>%
  summarise(observaciones = sum(!is.na(NO2)),
            mín = min(NO2, na.rm=TRUE),
            q25 = quantile(NO2, 0.25, na.rm=TRUE),
            media = mean(NO2, na.rm=TRUE),
            mediana = median(NO2, na.rm=TRUE),
            std = sd(NO2, na.rm=TRUE),
            q75 = quantile(NO2, 0.75, na.rm=TRUE),
            máx = max(NO2, na.rm=TRUE))

resumen_estaciones_NO2
```

```
## # A tibble: 9 x 9
##   Estación             observaciones   mín   q25 media mediana   std   q75 máx
##   <fct>                        <int> <dbl> <dbl> <dbl>   <dbl> <dbl> <dbl> <dbl>
## 1 Avda. Francia                50002     1     9  23.6    17    21.0    32   219
## 2 Bulevard Sud                 49524     1    13  29.3    24    22.4    40   229
## 3 Molí del Sol                 42118     1     7  19.2    15    16.3    26   144
## 4 Pista Silla                  51128     1    12  31.2    26    23.2    45   184
## 5 Politécnico                  50652     1     5  16.8    10    17.2    23   142
## 6 Puerto llit antic T~          3913     2    10  23.8    20    17.3    33   101
## 7 Puerto Moll Trans. ~          8286     1    12  26.7    21    20.1    37   153
## 8 Puerto Valencia              21048     0    10  27.5    21.8  23.1  38.8   185
## 9 Viveros                      49253     1     8  22.5    16    19.5    31   160
```

Destacamaos valores bajos tanto en media como en mediana para las estaciones de `Molí del Sol` y `Politécnico`, así como un valor máximo bajo para `Puerto llit antic Túria`. También cabe destacar los picos de concentración de este contaminante que se han alcanzado en las estaciones de `Avda. Francia` y `Bulevard Sud`. Además, observamos que todas las medias se encuentran por encima de las medianas, por lo que la distribución de NO_2 presenta una asimetría positiva.

Visualizamos a continuación los estadísticos correspondientes al ozono (O_3):

```
resumen_estaciones_O3 <- datos_filtrados %>%
  filter(!(Estación %in% estaciones_descartadas)) %>%
  group_by(Estación) %>%
  summarise(observaciones = sum(!is.na(O3)),
            mín = min(O3, na.rm=TRUE),
            q25 = quantile(O3, 0.25, na.rm=TRUE),
            media = mean(O3, na.rm=TRUE),
            mediana = median(O3, na.rm=TRUE),
            std = sd(O3, na.rm=TRUE),
            q75 = quantile(O3, 0.75, na.rm=TRUE),
            máx = max(O3, na.rm=TRUE))
```

```
resumen_estaciones_O3
```

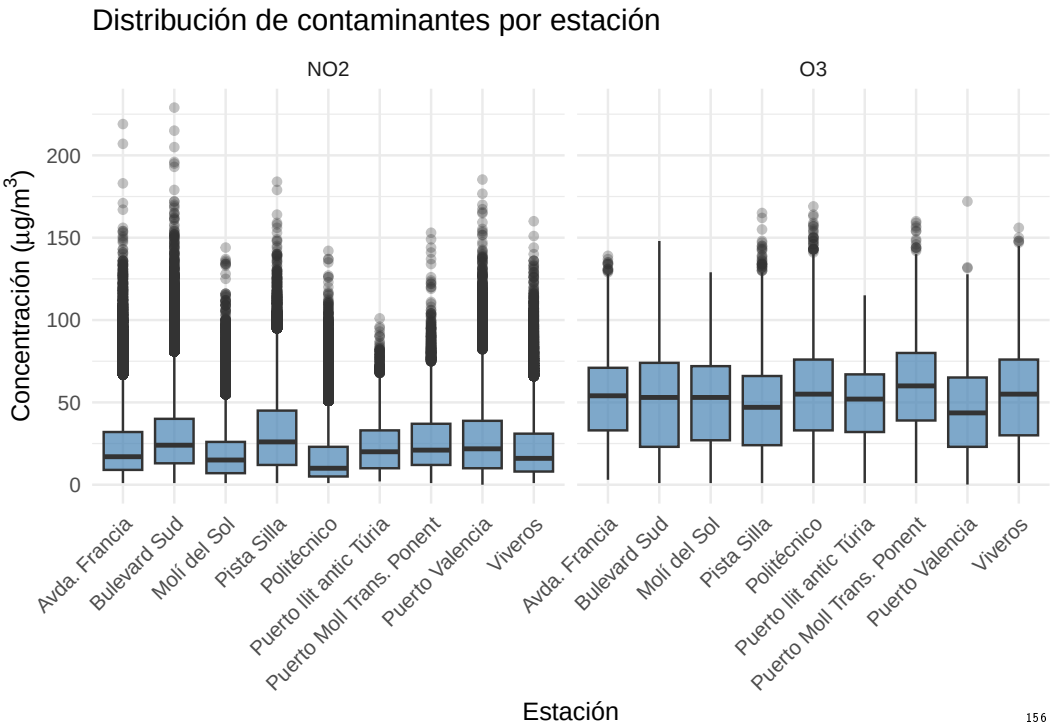
```
## # A tibble: 9 x 9
##   Estación            observaciones   mín   q25 media mediana   std   q75 má
##   <fct>                       <int> <dbl> <dbl> <dbl>   <dbl> <dbl> <dbl> <dbl
## 1 Avda. Francia               50588   3      33  51.8    54    26.2  71    13
## 2 Bulevard Sud                49614   1      23  50.5    53    30.0  74    14
## 3 Molí del Sol                43028   1      27  50.5    53    27.3  72    12
## 4 Pista Silla                 48690   1      24  46.2    47    27.1  66    16
## 5 Politécnico                 50955   1      33  54.5    55    28.7  76    16
## 6 Puerto llit antic T~         3856   1      32  49.0    52    24.0  67    11
## 7 Puerto Moll Trans. ~         8183   1      39  59.3    60    28.5  80    16
## 8 Puerto Valencia             19792   0.1    23  44.9    43.6  26.9  65.1  17
## 9 Viveros                     51423   1      30  53.5    55    29.5  76    15
```

Observamos que, en general, las concentraciones de ozono no difieren demasiado de unas estaciones a otras. A diferencia de lo observado con el dióxido de nitrógeno, los valores de las medias y medianas son prácticamente iguales.

4.2. Visualización de los contaminantes

Pasamos ahora a visualizar gráficamente como se distribuyen los distintos contaminantes por estación:

```
datos_filtrados %>%
  filter(!(Estación %in% estaciones_descartadas)) %>%
  select(Estación, NO2, O3) %>%
  gather(key="Contaminante", value="Concentración", NO2, O3) %>%
  ggplot(aes(x = Estación, y = Concentración)) +
    geom_boxplot(fill = "steelblue", alpha = 0.7,
                 outlier.alpha = 0.3, na.rm = TRUE) +
    facet_wrap(~Contaminante) +
    labs(title = "Distribución de contaminantes por estación",
         x = "Estación", y = expression("Concentración ("*mu*"g/m"^3*")")) +
    theme_minimal() +
    theme(axis.text.x = element_text(angle = 45,hjust = 1))
```



Comentaremos que podemos observar en este gráfico:

- En primer lugar, vemos que, en cada estación, el NO_2 presenta concentraciones centrales inferiores al O_3. Además el rango intercuartílico del NO_2 es menor que el del 0_3, luego sus valores centrales se encuentran más concentradas. Sin embargo, el NO_2 muestra un mayor número de valores atípicos y alcanza picos de concentración más altos, en general, que los del O_3. Estos valores representan episodios de concentración de los contaminantes muy elevados.
- **Distribución del NO_2 por estación**: observamos que todas las estaciones presentan distribuciones asimétricas a la derecha; luego, aunque la mayor parte de las mediciones se concentra en valores bajos, existen periodos puntuales donde las concentraciones de NO_2 alcanzan valores muy altos. Destacamaos también que:
  - `Pista de silla` presenta una de las concentraciones medianas más elevadas, así como la mayor dispersión de valores centrales.
  - `Politécnico` presenta la concentración mediana más baja, así como los valores centrales menos dispersos.
  - Las estaciones de `Avda Francia` y `Bulevard Sud` presentan los mayores picos de concentración
- **Distribución del 0_3 por estación**: observamos distribuciones menos asimétricas que en el caso del NO_2, aunque la mayor parte de las mediciones se concentran en valores más altos. Destacamos también:
  - `Puerto Moll Trans. Ponent` presenta la concentración mediana más elevada, mientras que `Puerto Valencia` presenta la concentración mediana más baja.
  - Las cajas están, en general, centradas respecto a la mediana, por lo que parece que el O_3 presenta una distribución más equilibrada de sus valores centrales.
- Por último, es interesante destacar que las estaciones que presentan mayores concentraciones de NO_2 no necesariamente presentan mayores concentraciones de O_3, y viceversa. Por ejemplo

- `Politécnico` presenta una de las concentraciones medianas más bajas de NO_2, mientras que su concentración mediana de O_3 es de las más altas.
- `Pista silla` presenta una de las concentraciones medianas más altas de NO_2, mientras que su concentración mediana de O_3 es de las más bajas.

5. Análisis temporal

Esta sección responde a la pregunta *¿cómo evolucionan los contaminantes a lo largo del tiempo y se observa estacionalidad?* Se estudian tres escalas: la serie diaria completa (con el efecto del estado de alarma de 2020), la estacionalidad mensual y el ciclo a lo largo del día. Se trabaja con los datos horarios originales (`datos`), calculando las medias con `na.rm = TRUE`, es decir, sin rellenar los valores perdidos.

```
library(dplyr); library(tidyr); library(lubridate); library(ggplot2)

# Variables de calendario con lubridate poniendo lunes como primer día de la seman
datos <- datos %>%
  mutate(
    año       = year(Fecha), # extraemos año, mes y día de la semana de la fecha
    mes        = month(Fecha, label = TRUE, abbr = TRUE),
    dow        = wday(Fecha, week_start = 1),
    fin_semana = dow >= 6, # definimos fin de semana como sábado y domingo
    hora_num   = hour(hms(Hora)) # extraemos unicamente el numero de la hora
  )
```

```
# # Definimos los periodos de estado de alarma para 2019, 2020 y 2021
en_alarma_2020 <- datos$Fecha >= as.Date("2020-03-14") & datos$Fecha <= as.Date("2
en_alarma_2021 <- datos$Fecha >= as.Date("2021-03-14") & datos$Fecha <= as.Date("2
en_alarma_2019 <- datos$Fecha >= as.Date("2019-03-14") & datos$Fecha <= as.Date("2

# Calculamos la media de NO2 para cada período
no2_2019   <- mean(datos$NO2[en_alarma_2019], na.rm = TRUE)
no2_2020   <- mean(datos$NO2[en_alarma_2020], na.rm = TRUE)
no2_2021   <- mean(datos$NO2[en_alarma_2021], na.rm = TRUE)

# Calculamos la variación porcentual de NO2 entre los años
var_alarma_2019 <- abs(round(100 * (no2_2020 - no2_2019) / no2_2019, 1))
var_alarma_2021 <- abs(round(100 * (no2_2021 - no2_2020) / no2_2020, 1))

cat("El No2 un año antes del inicio del estado de alarma fue un", var_alarma_2019,
```

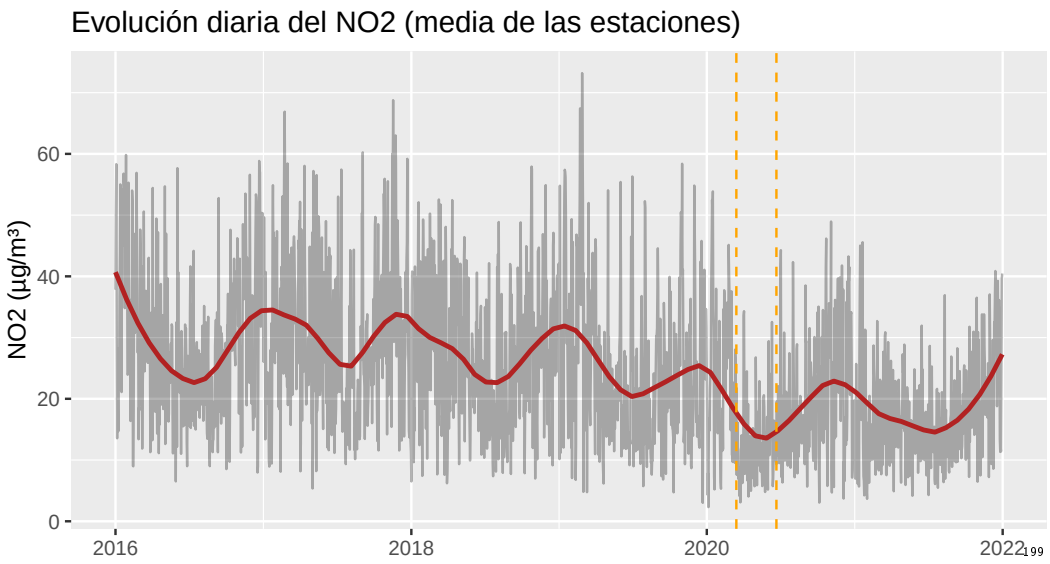
```
## El No2 un año antes del inicio del estado de alarma fue un 44.1 % mas que duran
```

5.1. Serie diaria y estado de alarma

Las líneas discontinuas naranjas delimitan el estado de alarma por la COVID-19 en España (14 de marzo al 21 de junio de 2020). La curva roja es un ajuste suavizado (`geom_smooth`) de la media diaria de todas las estaciones.

```
# Graficamos la evolución diaria del NO2 con suavizado y líneas verticales para el
datos %>%
  group_by(Fecha) %>% # Agrupamos por fecha para calcular la media diaria
  summarise(no2_global = mean(NO2, na.rm = TRUE)) %>% # Calculamos la media diaria
  ggplot(aes(x = Fecha, y = no2_global)) +
  geom_line(alpha = 0.3) +
  geom_smooth(method = "loess", span = 0.15, colour = "firebrick", se = FALSE) +
```

```
  geom_vline(xintercept = as.Date(c("2020-03-14", "2020-06-21")),
             linetype = "dashed", colour = "orange") +
  labs(title = "Evolución diaria del NO2 (media de las estaciones)",
       x = NULL, y = "NO2 (µg/m³)")
```

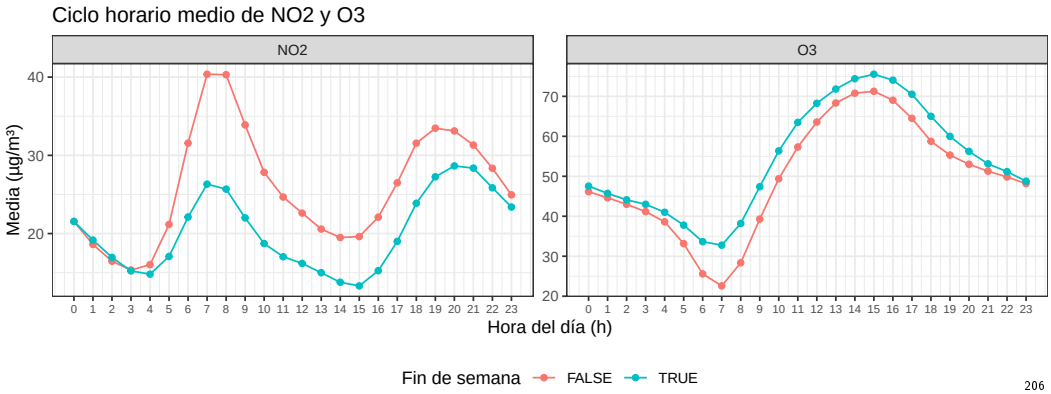


Se puede observar que la concentración de NO2 disminuyó drásticamente durante el estado de alarma, lo que refleja la reducción de la actividad humana y del tráfico de vehículos. La línea roja suavizada muestra claramente esta tendencia, con un pico antes del confinamiento y una caída significativa durante el período señalado por las líneas discontinuas naranjas.

5.2. Ciclo horario: laborables frente a fines de semana

```
# Calcular el ciclo horario de NO2 y O3 para días laborables y fines de semana
ciclo_hora <- datos %>%
  group_by(hora_num, fin_semana) %>%  # Agrupamos por hora y tipo de día (laborabl
  summarise(NO2 = mean(NO2, na.rm = TRUE),  # Calculamos la media de NO2 y O3, ign
            O3  = mean(O3,  na.rm = TRUE)) %>%
  pivot_longer(c(NO2, O3), names_to = "contaminante", values_to = "media") # Pasam

# Graficar el ciclo horario de NO2 y O3
ggplot(ciclo_hora, aes(x = hora_num, y = media, colour = fin_semana)) +
  geom_line() +
  geom_point() +
  facet_wrap(~ contaminante, scales = "free_y") +
  scale_x_continuous(breaks = 0:23) +
  labs(title = "Ciclo horario medio de NO2 y O3",
       x = "Hora del día (h)", y = "Media (µg/m³)", colour = "Fin de semana") +
  theme_bw() +
  theme(legend.position = "bottom",
        axis.text.x = element_text(size = 7))
```



El gráfico revela tres patrones clave. El NO2 depende directamente del tráfico, con dos picos en horas punta (7-9h y 19-21h) y niveles más bajos los fines de semana. El O3, al formarse con luz solar, alcanza su máximo a mediodía y cae de noche. Además, el O3 sube los fines de semana porque la menor emisión de NO2 permite que se acumule.

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.