MDPI

Article

Análisis exploratorio de la calidad del aire en València

Jose Luis, Marcos[1]

[1] Máster en Ciencia de Datos Universitat de València; correo@ejemplo.com

Simple Summary: Proyecto de la asignatura Análisis Exploratorio de Datos (AED) sobre la calidad del aire en Valencia.

Abstract: Resumen

Keywords: calidad del aire; contaminantes; NO2; PM10; O3; análisis exploratorio

Índice del proyecto

1. Introducción 2
2. Objetivo del proyecto 2
3. Preparación y acondicionamiento de datos 2
4. Análisis visual de datos 5

Citation: Apellido, N. Análisis exploratorio de la calidad del aire en València. *Journal Not Specified* **2023**, *1*, 0. https://doi.org/

Received:
Revised:
Accepted:
Published:

Copyright: © 2026 by the author. Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

1. Introducción

Este proyecto aborda un problema real de análisis de datos ambientales dentro de la asignatura de *Análisis Exploratorio de Datos* (AED) del Máster en Ciencia de Datos de la UV. Para llevarlo a cabo, utilizamos el registro oficial ("*Datos horarios de calidad del aire desde 2016*") del portal de datos abiertos del Ayuntamiento de València, procesado bajo el nombre de *calidad_aire.csv*.

Sabiendo que la atmósfera funciona como un sistema dinámico donde las emisiones de origen antrópico y las variables meteorológicas condicionan la concentración de contaminantes, emplearemos el análisis exploratorio como herramienta para transformar los datos brutos en información interpretable, para así evaluar la calidad del aire en la ciudad de València.

2. Objetivo del proyecto

El objetivo de este proyecto es llevar a cabo un análisis exploratorio de datos de la calidad del aire en Valencia, focalizándonos en los contaminantes principales con mayor registro (NO_2, O_3, SO_2) y en las variables meteorológicas (temperatura, presión, radiación y humedad). Para ello, realizaremos un proceso de depuración, transformación (Data Wrangling) y visualización de datos en R, de tal manera que logremos caracterizar el comportamiento estadístico del sistema atmosférico.

Para guiar el análisis exploratorio y dar validez física a los resultados, el proyecto busca responder las siguientes preguntas de investigación:

- ¿Cómo se distribuyen los niveles de los principales contaminantes (NO_2, O_3, SO_2) entre las estaciones de medición de la ciudad?
- ¿Cómo evolucionan los contaminantes a lo largo del tiempo?,¿se observa estacionalidad?

3. Preparación y acondicionamiento de datos

3.0.1. Fuente de datos, importación y conversión:

El análisis parte del registro oficial "*Datos horarios de calidad del aire desde 2016*", obtenido del portal de datos abiertos del Ayuntamiento de Valencia. El formato elegido es CSV de tal manera que podamos representar los datos en una tabla, donde las columnas se separan punto y coma y las filas por saltos de línea. El archivo se procesa bajo el nombre de *calidad_aire.csv*.

Según la teoría tratada, datos recién importados se consideran *Raw Data* y contienen inconsistencias que impiden un análisis directo. Por ello, el proceso de acondicionamiento exige transformar el conjunto en un formato *Technically Correct Data*.

El primer paso es importarlos desde la carpeta *data* mediante una ruta relativa que evite dependencias absolutas del equipo:

```
#Cargamos la librería "readr"
library(readr)

#Importamos usando ruta relativa
datos <- read.csv("calidad_aire.csv", sep = ";", fileEncoding = "UTF-8")
```

Para estudiar la estructura inicial del conjunto de datos y verificar su volumen, ejecutamos las funciones de inspección básicas (*str()*, *head()*, *tail()* y *summary()*):

```
#Número de filas y columnas en total
dim(datos)

#Inspeccionamos estructura interna de las variables
str(datos)
```

```r
#Observamos la columna Fecha correctamente convertida a tipo POSIXct.

#Visualizamos primeras y últimas filas
head(datos)
tail(datos)

#Resumen estadística preliminar
summary(datos)

colnames(datos)
```

Al examinar los resultados de esta exploración inicial observamos que el conjunto cuenta con 449.026 observaciones (filas) y 27 variables (columnas):

- La columna "Fecha" se ha importado como texto plano (*chr*) e incluye una letra "T" intermedia (ej. 2020-01-01T00:00:00), lo que impide a R tratarla como una línea de tiempo real.
- Variables cualitativas como "Día.de.la.semana", "Hora" y "Estación" figuran como texto plano (*chr*), convertirlas a factores es indispensable para que R las trate como variables categóricas permitiendo así que los gráficos operen de manera eficiente posteriormente.
- En el *summary* observamos que las variables con mayor número de *NAs* son ("C6H6" con 402.660, "C7H8" con 402.240 y el "C8H10" con 402.087).Muy cerca se sitúan el "NH3" con 401.307 y la variable "Ruido" con 397.324.
- El *summary* también refleja una anomalía física puntual, la variable "Radiación" muestra un valor mínimo negativo imposible de -7.0, requiriendo una corrección.

Una vez detectadas estas deficiencias en el formato bruto, aplicamos las herramientas de las librerías lubridate y dplyr para corregir los dos primeros puntos anteriores, corregir el formato de la columna "Fecha" y convertir "Día.de.la.semana", "Hora" y "Estación" a factor:

```r
#Cargamos librerías
library(lubridate)
library(dplyr)

#Convertimos la columna Fecha a formato POSIXct
datos$Fecha <- as.POSIXct(datos$Fecha, format = "%Y-%m-%dT%H:%M:%S", tz = "UTC")

#Convertimos variables cualitativas a factores para facilitar el filtrado y agrupa
datos <- datos %>%
  mutate(
    Estación = as.factor(Estación),
    Día.de.la.semana = as.factor(Día.de.la.semana),
    Hora = as.factor(Hora))

#Verificamos las transformaciones
str(datos[c("Fecha", "Día.de.la.semana", "Hora", "Estación")])
```

3.0.2. Selección de variables y filtrado

Continuamos corrigiendo las observaciones anteriores. Recordamos que los contaminantes mencionados anteriormente como el benceno, tolueno y xileno, presentan

pérdidas masivas de datos ($> 400.000 NAs$), esto valida la decisión de descartar las columnas prácticamente vacías ya que mantenerlas carece de rigor físico y entorpece el análisis exploratorio.

Sin embargo, los contaminantes principales ("NO2", "O3" y "SO2") y las variables meteorológicas ("Temperatura", "Humedad.Relativa", "Presión", "Precipitación") cuentan con una completitud altísima, registrando apenas entre 13,000 y 16,000 NAs. Por ello, empleamos paquete *dplyr*, concretamente aplicamos *select()* para conservar exclusivamente estas variables de interés de tal manera que la dimensión resultante será 449026x16:

```
# Seleccionamos las variables de interés y filtramos
datos_filtrados <- datos %>%
  select(
    Fecha, Hora, Día.de.la.semana, Estación,
    NO, NO2, NOx, O3, SO2, PM2.5, PM10,
    Temperatura, Humedad.relativa, Presión, Radiación, Precipitación
  ) %>%
  filter(!is.na(Fecha)) # Aseguramos coherencia temporal eliminando nulos críticos

# Verificamos las dimensiones resultantes del dataset depurado
dim(datos_filtrados)
```

3.0.3. Valores perdidos NAs e imputación:

Aunque hayamos seleccionado las variables de interés, el conjunto de datos aún presenta NAs en los contaminantes principales y meteorológicos, además de la anomalía física detectada en la radiación. Ambos deben resolverse antes de proceder con la visualización.

Por un lado, la "Radiación" no puede registrar valores negativos, para solucionar esta inconsistencia sin descartar toda la observación, empleamos la gramática de *dplyr*, concretamente *mutate* para reasignar dicho valor anómalo a NA:

```
#Convertimos en NA los valores negativos de Radiación
datos_filtrados <- datos_filtrados %>%
  mutate(Radiación = ifelse(Radiación < 0, NA, Radiación))
```

Por otro lado, es necesario cuantificar los NAs en las variables conservadas para decidir si aplicar una imputación o excluirlos con (na.rm = TRUE), evitando así sesgar los datos originales.

```
#Contabilizamos los NAs por columna
colSums(is.na(datos_filtrados))

dim(datos_filtrados)
```

El recuento revela que las columnas "Fecha", "Hora", "Día.de.la.semana" y "Estación" presentan completitud absoluta (0 NAs). Las variables meteorológicas muestran una alta completitud, destacando la "Presión" (13.753 NAs), la "Precipitación" (14.525 NAs), la "Radiación" (16.380 NAs) y la "Temperatura" (16.827 NAs).

Así mismo, los contaminantes principales (NO2, O3, SO2, y NOx) acumulan un volumen ligeramente alto de ausencias (oscilando entre 96.232 NAs en el NO2 y 124.888 NAs en el SO2), así como las columnas de partículas en suspensión (PM2.5 PM10) registrando el número de NAs más elevado, 226.614 y 226.609 respectivamente.

Descartamos la eliminación de filas, pues destruiría la continuidad de la serie temporal. También prescindimos de la imputación masiva mediante medias o medianas, ya que rellenar miles de huecos con un valor constante reduciría artificialmente la varianza y suavizaría los picos reales de contaminación.

Por tanto, se opta por preservar los NAs en el dataset y gestionarlos de forma local mediante el argumento *na.rm = TRUE*, operando así únicamente con los registros reales disponibles sin alterar la dinámica atmosférica.

Con un volumen final de 449.026 observaciones y 16 variables, el dataset queda estructurado en un formato sólido (*Technically Correct Data*) para iniciar la fase de Análisis Visual donde daremos respuesta a las preguntas de investigación planteadas.

4. Análisis visual de datos

4.0.1. Análisis univariante

4.0.2. Análisis temporal y estacionalidad

4.0.3. Identificación de períodos críticos

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.