MDPI

Article

Análisis exploratorio de la calidad del aire en València

Jose Luis, Marcos[1]

[1] Máster en Ciencia de Datos Universitat de València; correo@ejemplo.com

Simple Summary: Proyecto de la asignatura Análisis Exploratorio de Datos (AED) sobre la calidad del aire en Valencia.

Abstract: Resumen

Keywords: calidad del aire; contaminantes; NO2; O3; análisis exploratorio

Índice del proyecto

1. Introducción y objetivos **2**

2. Preparación y acondicionamiento de datos **2**
2.1. Conversión y selección de variables: 2
2.2. Correción de anomalías y getsión de *NAs* 3

3. Matriz de correlación entre contaminantes y variables meteorológicas **4**

4. Distribución de los principales contaminantes entre las estaciones de medición **5**
4.1. Comparación entre contaminantes 6
4.2. Distribución del $\mathbf{NO_2}$ por estación 7
4.3. Distribución del $\mathbf{O_3}$ por estación 7

5. Análisis temporal **7**
5.1. Serie diaria y estado de alarma 8
5.2. Tendencia y estacionalidad anual 9
5.3. Ciclo horario: laborables frente a fines de semana 10

6. Discusión outliers **10**

Citation: Apellido, N. Análisis exploratorio de la calidad del aire en València. *Journal Not Specified* **2024**, *1*, 0. https://doi.org/

Received:
Revised:
Accepted:
Published:

Copyright: © 2026 by the author. Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

1. Introducción y objetivos

Este proyecto aborda un análisis exploratorio de datos (AED) de la calidad del aire en la ciudad de Valencia. Para ello, utilizamos los registros horarios oficiales del portal de datos abiertos del Ayuntamiento (*Datos horarios de calidad del aire desde 2016*), procesados bajo el nombre de *calidad_aire.csv*.

Sabiendo que la atmósfera es un sistema dinámico condicionado por factores antrópicos y meteorológicos, el objetivo es transformar los datos brutos (*Raw Data*) en información interpretable (*Technically Correct Data*) mediante un proceso de depuración, transformación y visualización de datos en *R*. De tal manera que podamos estudiar el comportamiento de los contaminantes y su relación con variables meteorlógicas.

Para orientar el estudio, el proyecto se guía en torno a dos preguntas clave:

- ¿Cómo se distribuyen las concentraciones de (NO_2 y O_3) entre las estaciones de medición?
- ¿Cómo evolucionan ambos contaminantes a lo largo del tiempo?¿Presentan estacionalidad?

2. Preparación y acondicionamiento de datos

2.1. Conversión y selección de variables:

Tras descargar en formato *csv* e importar el archivo en *R* inspeccionamos su estructura, de tal amnera que obetenmos 449.026 observaciones y 27 variables.

```
#Importamos los datos usando una ruta relativa
datos <- read.csv("calidad_aire.csv", sep = ";", fileEncoding = "UTF-8")
#Número total de filas y columnas
dim(datos)
#Inspeccionamos la estructura de las variables
str(datos)
```

Detectamos que la variable `Fecha` aparece como una cadena de caracteres, al igual que `Día.de.la.semana`, `Hora` y `Estación`, aunque estas últimas representan variables categóricas.

Para corregirlo, convertimos Fecha a formato *POSIXct* y las tres variables cualitativas a factores. De esta manera, *R* puede interpretar correctamente la información temporal y categórica.

```
#Convertimos la columna Fecha a formato POSIXct
datos$Fecha <- as.POSIXct(datos$Fecha, format = "%Y-%m-%dT%H:%M:%S", tz = "UTC")

#Convertimos variables cualitativas a factores para facilitar el filtrado y agrupa
datos <- mutate(datos,
  Estación = as.factor(Estación),
  Día.de.la.semana = as.factor(Día.de.la.semana),
  Hora = as.factor(Hora))
```

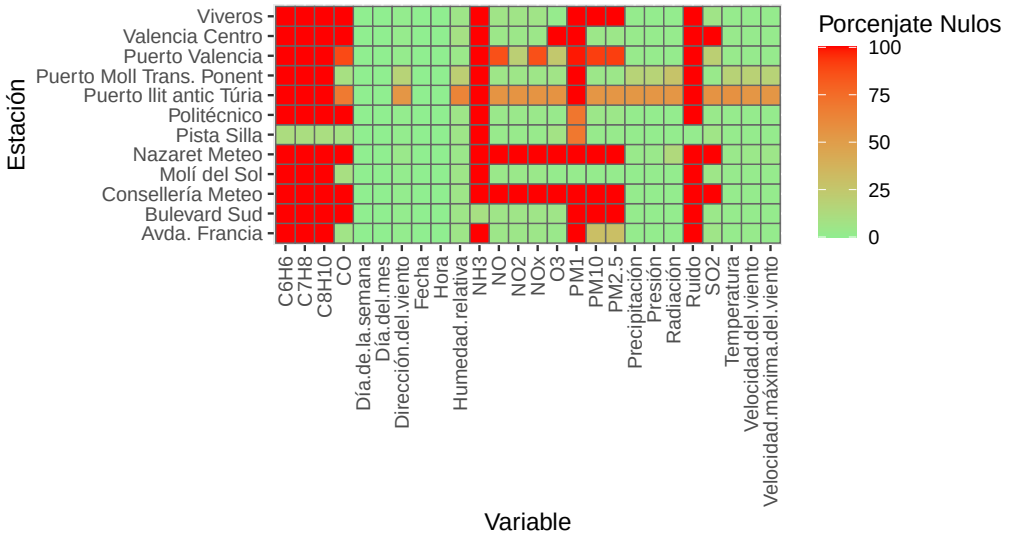
Una vez corregidos los formatos, estudiamos la completitud de las variables mediante el resumen estadístico.

```
summary(datos)
```

Observamos que variables como C6H6, C7H8 y C8H10 están prácticamente vacías, pues presentan más de 400.000 valores ausentes sobre las 449.026 observaciones iniciales. También destacan NH3 y Ruido, con cifras similares. Mantener estas variables aportaría muy poca información útil para el análisis exploratorio.

El mapa de calor permite visualizar cómo se distribuyen estas ausencias entre las distintas estaciones y variables, identificando también problemas de disponibilidad específicos de algunas estaciones.

```
# Visualizamos el porcentaje de NAs por estación y variable mediante un mapa de ca
datos %>%
  group_by(Estación) %>%                                    # nulos por estación
  summarise(across(everything(), ~ mean(is.na(.)) * 100)) %>%  # % de NAs por vari
  pivot_longer(-Estación, names_to = "Variable", values_to = "Porcentaje_Nulos") %
  ggplot(aes(Variable, Estación, fill = Porcentaje_Nulos)) +
  geom_tile(color = "grey40", linewidth = 0.3) +             # mapa de calor
  scale_fill_gradient(low = "lightgreen", high = "red", name="Porcenjate Nulos") +
  theme(axis.text.x = element_text(angle = 90, hjust = 1, vjust = 0.5))  # etiquet
```



Seleccionamos 16 variables para continuar trabajando: las variables temporales y Estación, los contaminantes candidatos y las variables meteorológicas. Dejamos fuera las otras 11 variables ya que presentan un elevado porcentaje de ausencias; además, no forman parte del objetivo de nuestro estudio.

```
# Seleccionamos las variables de interés
datos_filtrados <- select(datos, Fecha, Hora, Día.de.la.semana, Estación, NO, NO2,

# Verificamos las dimensiones resultantes del dataset depurado
dim(datos_filtrados)
```

2.2. *Correción de anomalías y getsión de* NAs .

Tras la selección, todavía debemos resolver algunas inconsistencias. En el *summary* detectamos un valor físicamente imposible de -7 en `Radiación`. En lugar de eliminar toda la fila, sustituimos únicamente ese valor por un NA, conservando el resto de mediciones.

```
#Convertimos en NA los valores negativos de Radiación
datos_filtrados <- mutate(datos_filtrados, Radiación = ifelse(Radiación < 0, NA, R
```

Contabilizamos ahora los valores ausentes. Las variables temporales y Estación no presentan NAs, mientras que los contaminantes y algunas variables meteorológicas mantienen ausencias.

```r
#Contabilizamos los NAs por columna
colSums(is.na(datos_filtrados))
```

En particular, el $N0_2$ presenta 96.232 NAs y el O_3, 122.897. Al volver al mapa de calor, observamos que `Consellería Meteo` y `Nazaret Meteo` presentan un 100 % de ausencias en ambos contaminantes, mientras que `Valencia Centro` no registra ninguna medición de O_3. Por ello, eliminamos todas las observaciones correspondientes a estas tres estaciones, pasando de 449.026 a 350.712 filas y de 12 a 9 estaciones.

```r
estaciones_descartadas <- c("Valencia Centro", "Consellería Meteo", "Nazaret Meteo
datos_filtrados <- filter(datos_filtrados, !(Estación %in% estaciones_descartadas)
```

Tras este filtrado, los valores ausentes se reducen a 24.788 en $N0_2$ y 24.583 en O_3.

Para gestionar los NAs restantes, descartamos tanto la eliminación indiscriminada de filas, que supondría perder observaciones y continuidad temporal, como la imputación masiva mediante medias o medianas, que podría reducir artificialmente la variabilidad y suavizar los picos reales de contaminación.

Por tanto, conservamos los valores ausentes y los gestionamos localmente mediante *na.rm = TRUE*, utilizando únicamente las mediciones disponibles.

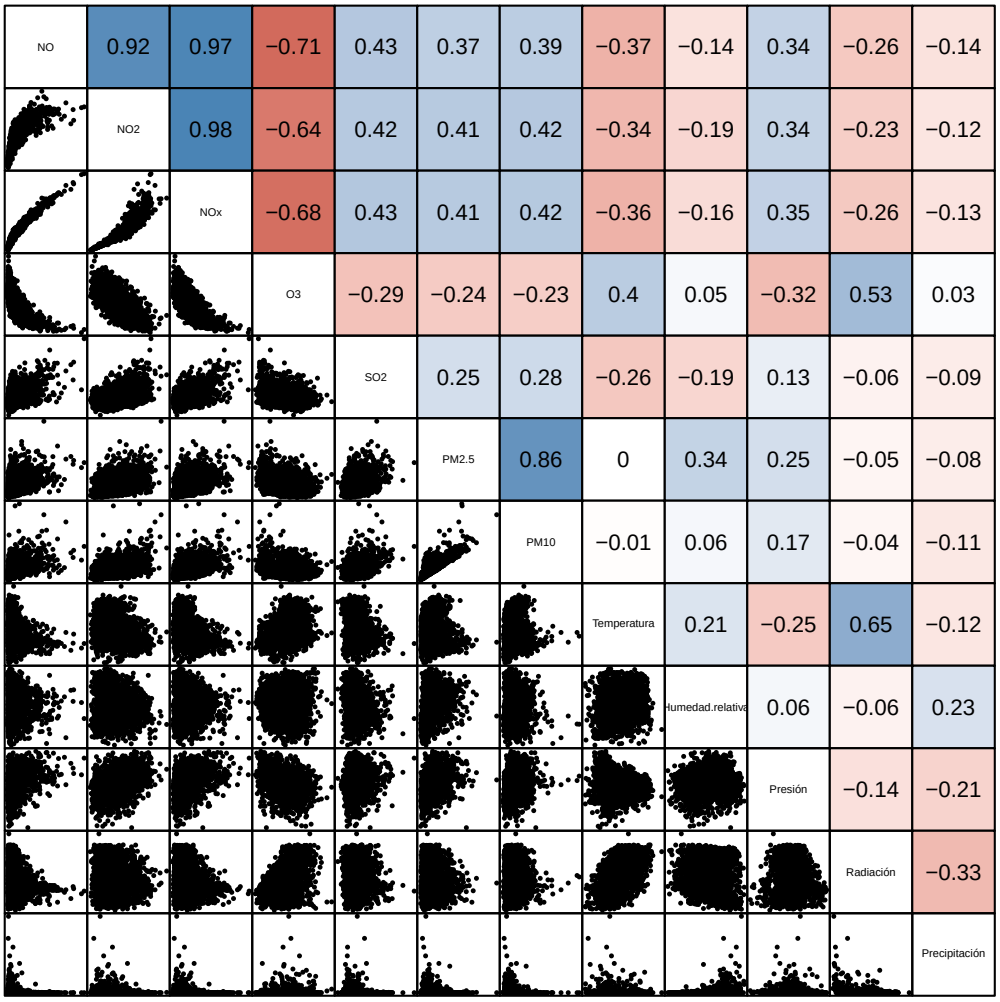
Finalmente, obtenemos un conjunto acondicionado de 350.712 observaciones y 16 variables,

3. Matriz de correlación entre contaminantes y variables meteorológicas

Calculamos correlaciones de Spearman sobre las medias diarias de las variables numéricas, agrupando las mediciones de las estaciones por día.

```r
# Definimos una paleta de colores para la correlación
paleta <- col_numeric(palette = c("firebrick", "white", "steelblue"), domain = c(-

# calculamos primero las medias diarias de las variables y representamos sus relac
datos_filtrados %>%
  group_by(dia = floor_date(Fecha, "day")) %>%
  summarise(across(where(is.numeric), ~ mean(.x, na.rm = TRUE))) %>%
  select(-dia) %>%
  pairs(gap = 0, xaxt = "n", yaxt = "n", cex.labels = 0.5,
        lower.panel = function(x, y, ...) points(x, y, pch = 16, cex = 0.5),
        upper.panel = function(x, y, ...) {
          correlacion <- cor(x, y, method = "spearman", use = "complete.obs")
          coords <- par("usr")
          rect(coords[1], coords[3], coords[2], coords[4], col = paleta(correlacio
          text(mean(coords[1:2]), mean(coords[3:4]), round(correlacion,2))
          })
```



Hay tres obseravciones clave:

- $N0_2$ y O_3 presentan una relación inversa (-0,64). Cuando las medias diarias de $N0_2$ son mayores, las de O_3 tienden a ser menores.
- $N0_2$ está muy correlacionado con NO (0,92) y NO_x (0,98) indicando que presentan comportamientos monótonos muy similares por lo que NO_2 puede servirnos como representante de interés para estudiar este grupo.
- El O_3 presenta una correlación positiva con la radiación, una relación que retomaremos al estudiar su comportamiento estacional.

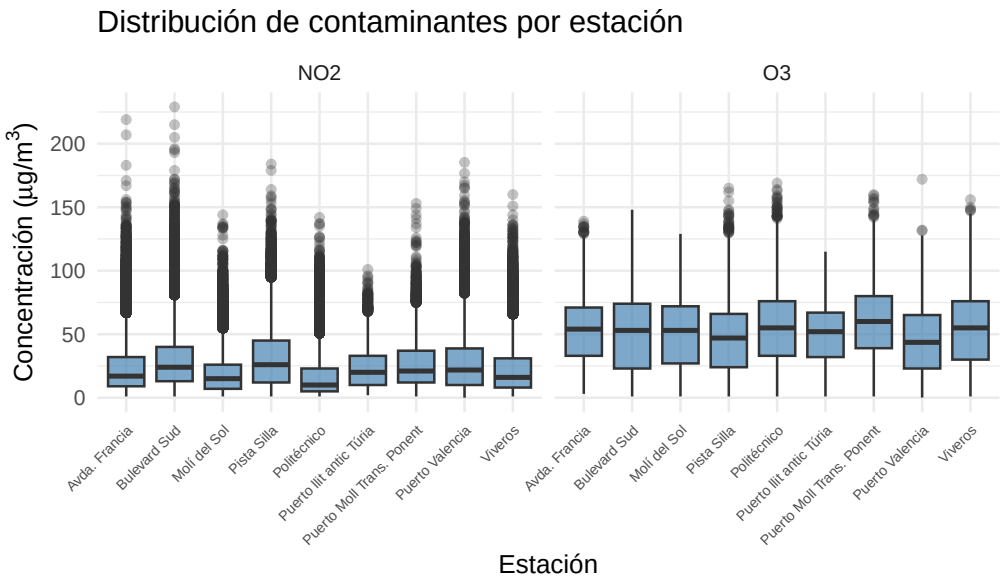
Estos resultados nos permiten centrar el análisis posterior en $N0_2$ y O_3, dos contaminantes con comportamientos diferenciados y una relación inversa apreciable. Eso sí, correlación no significa causalidad. La matriz orienta nuestro análisis, pero no demuestra por sí sola los mecanismos físicos que hay detrás.

4. Distribución de los principales contaminantes entre las estaciones de medición

Nos centramos ahora en dar respuesta a la primera pregunta formulada: ¿Cómo se distribuyen los niveles de NO_2 y O_3 entre las distintas estaciones de medición de la ciudad de Valencia? Para ello, visualizaremos como se distribuyen los distintos contaminantes por estación usando un boxplot para cada contaminante:

```
datos_filtrados %>% select(Estación, NO2, O3) %>%
  pivot_longer(cols=c(NO2, O3), names_to="Contaminante", values_to="Concentración"
  ggplot(aes(x = Estación, y = Concentración)) +
```

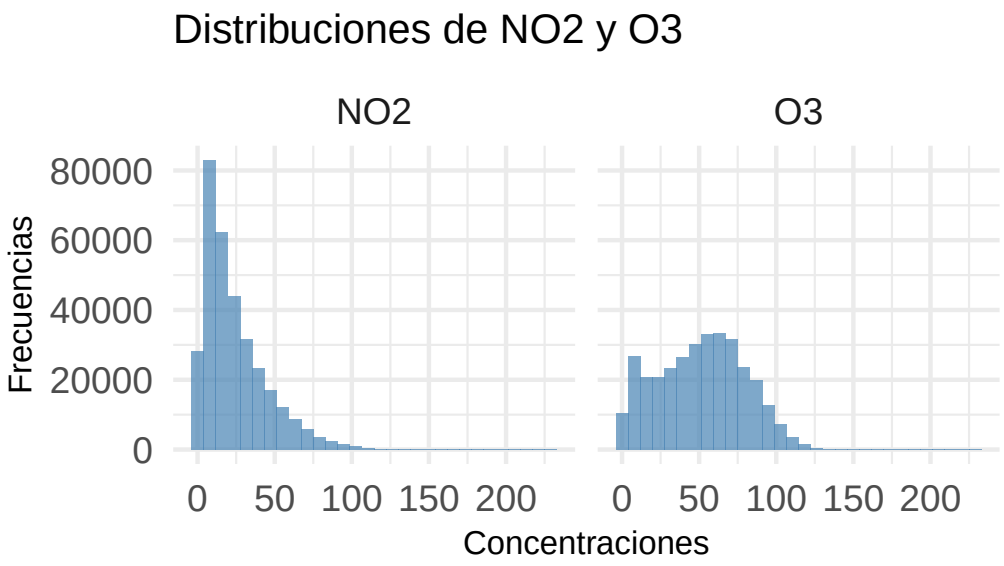
```
    geom_boxplot(fill = "steelblue", alpha = 0.7, outlier.alpha = 0.3, na.rm = TRU
    facet_wrap(~Contaminante) +
    labs(title = "Distribución de contaminantes por estación",
         x = "Estación", y = expression("Concentración ("*mu*"g/m"^3*")")) +
    theme_minimal() + theme(axis.text.x = element_text(angle = 45,hjust = 1, size=
```



4.1. Comparación entre contaminantes

En primer lugar, vemos que, en cada estación, el NO_2 presenta concentraciones centrales inferiores al O_3. Además el rango intercuartílico del NO_2 es menor que el del O_3, luego sus valores centrales se encuentran más concentrados. Sin embargo, el NO_2 muestra un mayor número de valores atípicos y alcanza picos de concentración más altos, en general, que los del O_3. Resaltar también que el NO_2 presenta una marcada asimetría hacia la derecha, mientras que el O_3 presenta una menor asimetría. Todos estos detalles los podemos visualizar mejor comparando sus histogramas.

```
datos_filtrados %>% select(NO2, O3) %>%
  pivot_longer(cols=c(NO2, O3), names_to="Contaminante", values_to="Concentración"
  ggplot(aes(Concentración)) +
    geom_histogram(fill = "steelblue", alpha = 0.7, na.rm = TRUE) +
    facet_wrap(~Contaminante) +
    labs(title="Distribuciones de NO2 y O3", x="Concentraciones", y="Frecuencias")
    theme_minimal() +
    theme(axis.title.x=element_text(size=8), axis.title.y=element_text(size=8),
          plot.title=element_text(size=10))
```



4.2. Distribución del $\mathbf{NO_2}$ *por estación*

Aunque, en general, la forma de la distribución parece no variar mucho entre estaciones, podemos resaltar algunas diferencias significativas. `Pista de silla` presenta una de las concentraciones medianas más elevadas, así como la mayor dispersión de valores centrales. De forma opuesta, `Politécnico` presenta la concentración mediana más baja, así como los valores centrales menos dispersos. Destaca también que las estaciones de `Avda Francia` y `Bulevard Sud` presentan los mayores picos de concentración

4.3. Distribución del $\mathbf{O_3}$ *por estación*

De nuevo, pese a la similitud de las distribuciones entre estaciones, destacamos algunas diferencias. `Puerto Moll Trans` presenta la concentración mediana más elevada, mientras que `Puerto Valencia` presenta la concentración mediana más baja. En oposición a lo que sucedía con el NO_2, las cajas están, en general, centradas respecto a la mediana, por lo que parece que el O_3 presenta una distribución más equilibrada de sus valores centrales.

Por último, es interesante destacar que las estaciones que presentan mayores concentraciones de NO_2 no necesariamente presentan mayores concentraciones de O_3, y viceversa. Por ejemplo:

- `Politécnico` presenta una de las concentraciones medianas más bajas de NO_2, mientras que su concentración mediana de O_3 es de las más altas.
- `Pista silla` presenta una de las concentraciones medianas más altas de NO_2, mientras que su concentración mediana de O_3 es de las más bajas.

Corroboramos cuantitativamente este comportamiento con el cálculo de la correlación lineal de Pearson entre el NO_2 y el 0_3, verificando cómo arroja un coeficiente negativo de -0.6 que confirma la relación inversa existente entre ambos contaminantes.

5. Análisis temporal

Esta sección responde a la pregunta *¿cómo evolucionan los contaminantes a lo largo del tiempo y se observa estacionalidad?* Se estudian tres escalas: la serie diaria completa (con el efecto del estado de alarma de 2020), la estacionalidad mensual y el ciclo a lo largo del día. Se trabaja con los datos horarios originales (`datos`), calculando las medias con `na.rm = TRUE`, es decir, sin rellenar los valores perdidos.

```
# Variables de calendario con lubridate poniendo lunes como primer día de la seman
datos <- datos %>%
  mutate(
```

```
    año       = year(Fecha), # extraemos año, mes y día de la semana de la fecha
    mes        = month(Fecha, label = TRUE, abbr = TRUE),
    dow        = wday(Fecha, week_start = 1),
    fin_semana = dow >= 6, # definimos fin de semana como sábado y domingo
    hora_num   = hour(hms(Hora)) # extraemos unicamente el numero de la hora
  )
```

```
# # Definimos los periodos de estado de alarma para 2019, 2020 y 2021
en_alarma_2020 <- datos$Fecha >= as.Date("2020-03-14") & datos$Fecha <= as.Date("2
en_alarma_2021 <- datos$Fecha >= as.Date("2021-03-14") & datos$Fecha <= as.Date("2
en_alarma_2019 <- datos$Fecha >= as.Date("2019-03-14") & datos$Fecha <= as.Date("2

# Calculamos la media de NO2 para cada período
no2_2019   <- mean(datos$NO2[en_alarma_2019], na.rm = TRUE)
no2_2020   <- mean(datos$NO2[en_alarma_2020], na.rm = TRUE)
no2_2021   <- mean(datos$NO2[en_alarma_2021], na.rm = TRUE)

# Calculamos la variación porcentual de NO2 entre los años
var_alarma_2019 <- abs(round(100 * (no2_2020 - no2_2019) / no2_2019, 1))
var_alarma_2021 <- abs(round(100 * (no2_2021 - no2_2020) / no2_2020, 1))

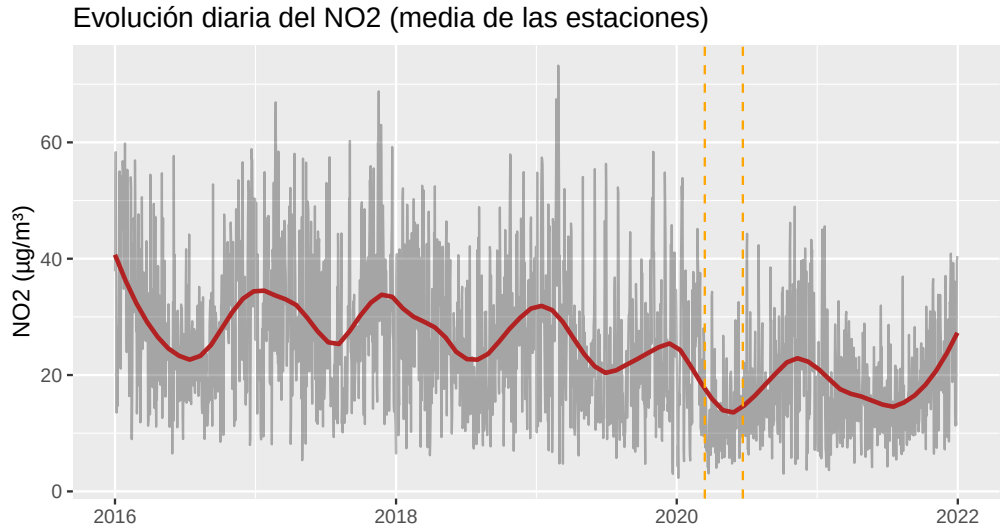
cat("El No2 un año antes del inicio del estado de alarma fue un", var_alarma_2019,
```

```
## El No2 un año antes del inicio del estado de alarma fue un 44.1 % mas que duran
```

5.1. Serie diaria y estado de alarma

Las líneas discontinuas naranjas delimitan el estado de alarma por la COVID-19 en España (14 de marzo al 21 de junio de 2020). La curva roja es un ajuste suavizado (`geom_smooth`) de la media diaria de todas las estaciones.

```
# Graficamos la evolución diaria del NO2 con suavizado y líneas verticales para el
datos %>%
  group_by(Fecha) %>% # Agrupamos por fecha para calcular la media diaria
  summarise(no2_global = mean(NO2, na.rm = TRUE)) %>% # Calculamos la media diaria
  ggplot(aes(x = Fecha, y = no2_global)) +
  geom_line(alpha = 0.3) +
  geom_smooth(method = "loess", span = 0.15, colour = "firebrick", se = FALSE) +
  geom_vline(xintercept = as.Date(c("2020-03-14", "2020-06-21")),
             linetype = "dashed", colour = "orange") +
  labs(title = "Evolución diaria del NO2 (media de las estaciones)",
       x = NULL, y = "NO2 (µg/m³)")
```

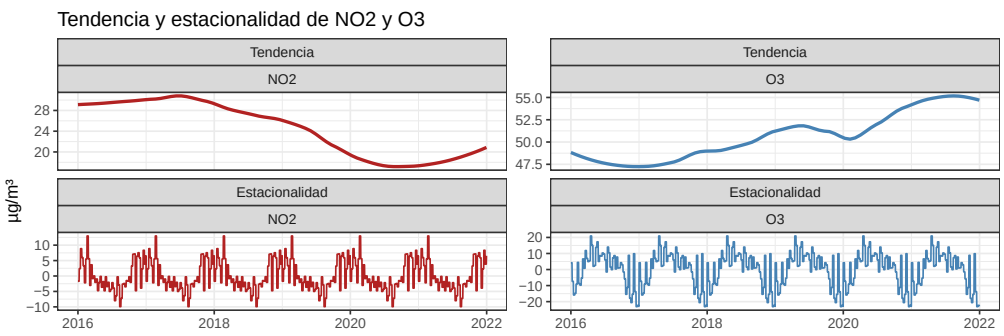


Se puede observar que la concentración de NO2 disminuyó drásticamente durante el estado de alarma, lo que refleja la reducción de la actividad humana y del tráfico de vehículos. La línea roja suavizada muestra claramente esta tendencia, con un pico antes del confinamiento y una caída significativa durante el período señalado por las líneas discontinuas naranjas.

5.2. Tendencia y estacionalidad anual

```r
# Descomposición de la serie temporal de NO2 y O3 en tendencia y estacionalidad
descomp <- datos_filtrados %>%
  pivot_longer(c(NO2, O3), names_to = "contaminante", values_to = "valor") %>%  #
  group_by(contaminante, Fecha) %>%                                              #
  summarise(valor = mean(valor, na.rm = TRUE)) %>%                               #
  group_by(contaminante, semana = week(Fecha)) %>%                               #
  mutate(m = mean(valor, na.rm = TRUE)) %>%                                      #
  group_by(contaminante) %>%                                                     #
  mutate(Estacionalidad = m - mean(unique(m)), Tendencia = valor - Estacionalidad)
  pivot_longer(c(Tendencia, Estacionalidad), names_to = "componente", values_to =
  mutate(componente = factor(componente, c("Tendencia", "Estacionalidad")))      #

# Gráfico de tendencia y estacionalidad de NO2 y O3
ggplot(descomp, aes(Fecha, y, colour = contaminante)) +
  geom_smooth(data = filter(descomp, componente == "Tendencia"), method = "loess",
  geom_line(data = filter(descomp, componente == "Estacionalidad")) +            #
  facet_wrap(componente ~ contaminante, ncol = 2, scales = "free_y") +           #
  scale_colour_manual(values = c(NO2 = "firebrick", O3 = "steelblue")) +         #
  labs(title = "Tendencia y estacionalidad de NO2 y O3", x = NULL, y = "µg/m³") +
  theme_bw() + theme(legend.position = "none")                                   #
```

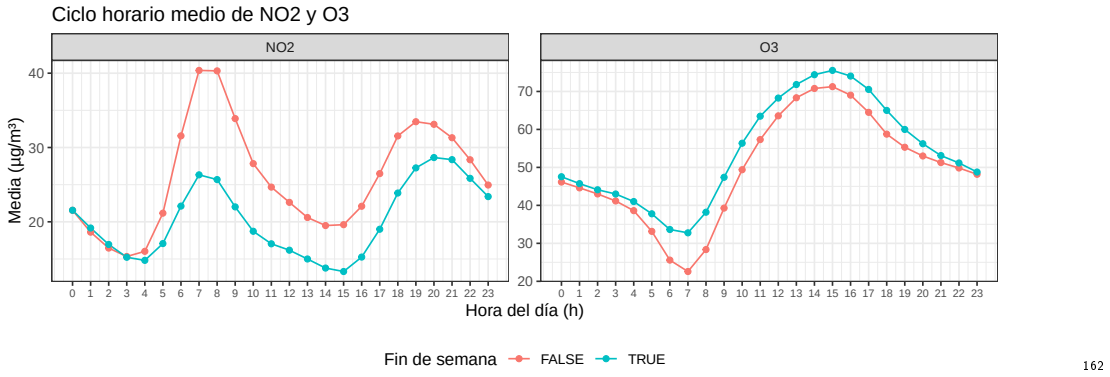


A partir de la descomposición STL se observan patrones opuestos. En la tendencia, el NO_2 desciende desde 2016, con una caída acusada en 2020 que se estabiliza después en valores mínimos, mientras que el O_3 muestra un ligero ascenso, coherente con la menor destrucción de ozono al haber menos NOx. En la estacionalidad, el NO_2 alcanza sus máximos en invierno por el mayor tráfico y la peor dispersión, y el O_3 en primavera y verano por la mayor radiación solar. El aspecto en dientes de sierra indica que el modelo, pese a ajustarse con frecuencia anual, captura también parte del ciclo diario de la serie horaria.

5.3. Ciclo horario: laborables frente a fines de semana

```
# Calcular el ciclo horario de NO2 y O3 para días laborables y fines de semana
ciclo_hora <- datos %>%
  group_by(hora_num, fin_semana) %>%  # Agrupamos por hora y tipo de día (laborabl
  summarise(NO2 = mean(NO2, na.rm = TRUE),  # Calculamos la media de NO2 y O3, ign
            O3  = mean(O3,  na.rm = TRUE)) %>%
  pivot_longer(c(NO2, O3), names_to = "contaminante", values_to = "media") # Pasam

# Graficar el ciclo horario de NO2 y O3
ggplot(ciclo_hora, aes(x = hora_num, y = media, colour = fin_semana)) +
  geom_line() +
  geom_point() +
  facet_wrap(~ contaminante, scales = "free_y") +
  scale_x_continuous(breaks = 0:23) +
  labs(title = "Ciclo horario medio de NO2 y O3",
       x = "Hora del día (h)", y = "Media (µg/m³)", colour = "Fin de semana") +
  theme_bw() +
  theme(legend.position = "bottom",
        axis.text.x = element_text(size = 7))
```



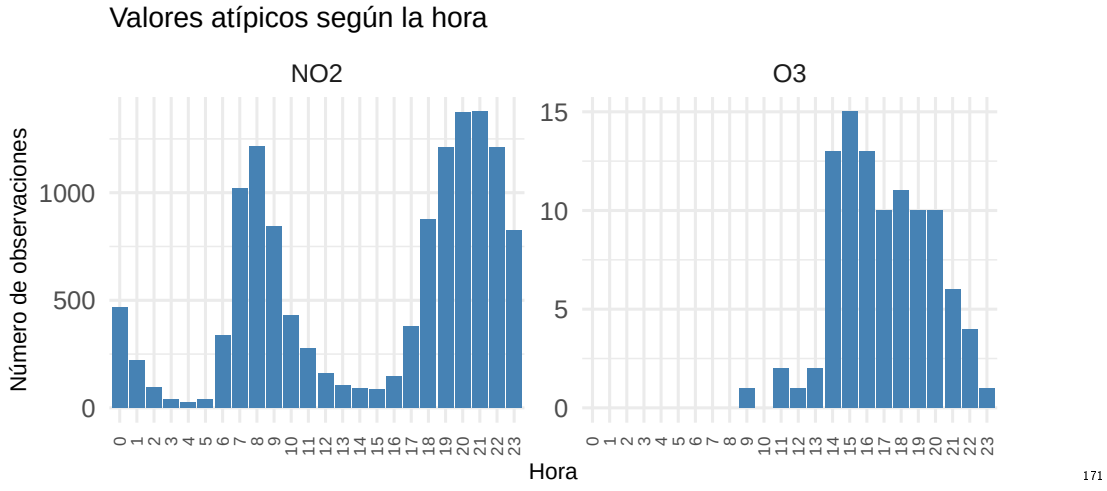
El gráfico revela tres patrones clave. El NO2 depende directamente del tráfico, con dos picos en horas punta (7-9h y 19-21h) y niveles más bajos los fines de semana. El O3, al formarse con luz solar, alcanza su máximo a mediodía y cae de noche. Además, el O3 sube los fines de semana porque la menor emisión de NO2 permite que se acumule.

6. Discusión outliers

Ya que conocemos la distribución de los contaminantes NO_2 y O_3 por horas, visualizaremos como se distribuyen por horas los valores atípicos que aparecen en el boxplot de contaminantes por estaciones:

```
# Convertimos la concentración y el tipo de contaminante en dos variables
datos_alargados <- datos_filtrados %>%
  select(Fecha, Hora, Día.de.la.semana, Estación, NO2, O3) %>%
```

```r
  pivot_longer(cols=c(NO2, O3), names_to="Contaminante", values_to="Concentración"
# Seleccionamos los límites por el criterio de boxplot
limites <- datos_alargados %>% group_by(Estación, Contaminante) %>%
  summarise(Q1 = quantile(Concentración, 0.25, na.rm=TRUE),
            Q3 = quantile(Concentración, 0.75, na.rm=TRUE), IQR = Q3 - Q1,
            .groups="drop") %>% mutate(Lim_inf = Q1 - 1.5 * IQR, Lim_sup = Q3 + 1.
# Calculamos los valores atípicos por dicho criterio
datos_atipicos <- datos_alargados %>%
  left_join(limites, by=c("Estación", "Contaminante")) %>%
  filter(!is.na(Concentración) & (Concentración < Lim_inf | Concentración > Lim_su
# Ordenamos los niveles del factor hora para que el gráfico se vea bien
datos_atipicos$Hora <- factor(datos_atipicos$Hora, levels = paste0(0:23, ":00:00")
# Graficamos
datos_atipicos %>% count(Contaminante, Hora) %>%
  ggplot(aes(x=Hora, y=n)) + geom_col(fill = "steelblue") +
  facet_wrap(~Contaminante, scales="free_y") +
  labs(title="Valores atípicos según la hora", x="Hora", y="Número de observacione
  scale_x_discrete(labels = function(x) sub(":.*", "", x)) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 90, hjust = 1, vjust = 0.5, size=6),
        axis.title.x = element_text(size=8), axis.title.y = element_text(size=8),
        plot.title=element_text(size=10))
```



Como ya hemos comentado, las concentraciones de NO_2 están estrechamente relacionadas con el tráfico, por lo que es coherente que los niveles más altos de de NO_2 se concentren principalmente en horas punta de tráfico (7-9h y 19-21h). Por otro lado, la formación de O_3 depende de la radiación solar y de temperatura elevada, por lo que tampoco es sorprendente que los valores atípicos se encuentren concentrados principalmente alrededor del mediodía, y vayan decreciendo con la caída del sol.

No obstante, este breve análisis sobre los valores atípicos detectados no debe entenderse como un criterio absoluto para determinar si son errores de medición o no, sino más bien como una primera aproximación a una discusión mucho más profunda. Si bien los valores detectados para el O_3 no estaban muy por encima, en general, de los bigotes; los valores detectados para el NO_2 alcanzaban concentraciones hasta más de 100 unidades por encima del límite superior. Por ello, sería también interesante estudiar en que estaciones se producen estos valores tan altos (si están localizadas en zonas con mucho o poco tráfico), en que día se produjeron, en que condiciones de temperatura y radiación, etc. Sin embargo, debido a la escasez de espacio, nos conformamos con dar una primera aproximación analizando la distribución de estos valores por horas.

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.