MDPI

Article

Análisis exploratorio de la calidad del aire en València

Noa Martín Hodar[1]

[1] Máster en Ciencia de Datos Universidad o centro de estudios València, España; correo@ejemplo.com

Simple Summary: Proyecto académico de análisis exploratorio de datos de calidad del aire en València.

Abstract: Resumen pendiente de redactar cuando se hayan completado los análisis.

Keywords: calidad del aire; València; NO2; PM10; O3; análisis exploratorio

Índice del proyecto

1. Introducción . . . **2**
1.1. Objetivo del proyecto . . . 2
1.2. Preguntas de investigación . . . 2

2. Datos . . . **2**
2.1. Fuentes de datos previstas . . . 2

3. calidad_aire.csv . . . **2**
3.1. Importación del fichero . . . 2
3.2. Conversión de la fecha y hora . . . 2
3.3. Estructura del conjunto de datos . . . 2
3.4. Primera revisión de los valores perdidos . . . 3

4. Acondicionamiento de los datos . . . **4**

5. Análisis de datos perdidos e imputación . . . **4**

6. Detección de valores atípicos . . . **4**

7. Análisis univariante . . . **4**

8. Análisis bivariante . . . **4**

9. Análisis temporal . . . **4**

10. Modelo predictivo . . . **4**

11. Discusión . . . **4**

12. Conclusiones finales . . . **4**

M. . . . **4**
M.1. . . . 4

N. . . . **5**

Citation: Apellido, N. Análisis exploratorio de la calidad del aire en València. *Journal Not Specified* **2023**, *1*, 0. https://doi.org/

Received:
Revised:
Accepted:
Published:

Copyright: © 2026 by the author. Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

1. Introducción

1.1. Objetivo del proyecto

El objetivo es realizar un análisis exploratorio de la calidad del aire en los 19 distritos de València, utilizando inicialmente el fichero "calidad_aire.csv" descargado del portal de datos abiertos del Ayuntamiento de Valencia. . . .

1.2. Preguntas de investigación

1. ¿Cómo se distribuyen los niveles de NO2, PM10 y O3 entre las estaciones de medición? ¿Hay diferencias entre distritos?
2. ¿Existe relación entre la densidad de población de cada distrito y sus niveles de contaminación?
3. ¿Cómo evolucionan los contaminantes a lo largo del tiempo? ¿Se observa estacionalidad?
4. ¿Qué días o períodos presentan valores atípicos?
5. ¿Se puede predecir si una estación superará el umbral diario de NO2 de la OMS a partir de variables meteorológicas y temporales?

2. Datos

2.1. Fuentes de datos previstas

Se prevé utilizar registros horarios de contaminantes y meteorología del Portal de Datos Abiertos del Ayuntamiento de València, información sobre la ubicación y el distrito de cada estación de medida, datos de población por distrito del Padrón Municipal e información sobre intensidad de tráfico de las espiras electromagnéticas. En esta primera versión se trabaja con `calidad_aire.csv`; . . .

3. calidad_aire.csv

3.1. Importación del fichero

El fichero se lee con separador de punto y coma. Para evitar depender de una ruta absoluta del ordenador, el código busca `calidad_aire.csv` en la carpeta del proyecto y, después, dentro de `data/`.

```
#Cargamos la librería "readr"
library(readr)

#Importamos usando ruta relativa
fichero <- "calidad_aire.csv"

datos <- read.csv(fichero, sep = ";", fileEncoding = "UTF-8")
```

3.2. Conversión de la fecha y hora

El archivo calidad_aire.csv trae la fecha con una letra "T" en medio (ej.:2020-01-01T00:00:00). R necesita interpretarla como una fecha real y no como un texto plano para poder hacer gráficos temporales después. Por lo que convertiremos la columna "Fecha" a formato fecha-hora real con as.POSIXct:

```
datos$Fecha <- as.POSIXct(datos$Fecha, format = "%Y-%m-%dT%H:%M:%S", tz = "UTC")
```

3.3. Estructura del conjunto de datos

Se revisa la estructura del conjunto de datos para comprobar los tipos de las variables y el número de observaciones y columnas.

```
str(datos)
```

```
## 'data.frame':    449026 obs. of  27 variables:
##  $ Fecha                       : POSIXct, format: "2020-01-01" "2020-01-01" ...
##  $ Día.de.la.semana            : chr  "Miércoles" "Miércoles" "Miércoles" "Miérc
##  $ Día.del.mes                 : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ Hora                        : chr  "0:00:00" "1:00:00" "2:00:00" "3:00:00" ...
##  $ Estación                    : chr  "Avda. Francia" "Avda. Francia" "Avda. Fra
##  $ PM1                         : int  NA NA NA NA NA NA NA NA NA NA ...
##  $ PM2.5                       : int  77 65 47 43 36 28 25 24 22 22 ...
##  $ PM10                        : int  83 70 51 46 39 30 27 26 24 24 ...
##  $ NO                          : int  16 20 16 16 10 2 2 6 8 6 ...
##  $ NO2                         : num  45 37 35 29 23 19 19 22 17 19 ...
##  $ NOx                         : int  69 68 61 53 39 23 22 32 29 27 ...
##  $ O3                          : num  3 3 3 3 3 3 3 3 3 5 ...
##  $ SO2                         : num  7 5 5 5 4 4 3 4 4 3 ...
##  $ CO                          : num  0.2 0.2 0.1 0.1 0.1 0.1 0.1 0.1 0.1 0.1 ...
##  $ Velocidad.del.viento        : num  1.3 1.9 2.2 1.7 1.2 2.1 0.3 1.5 2.5 0.4 ...
##  $ Dirección.del.viento        : int  313 315 316 310 312 314 304 317 315 298 ...
##  $ NH3                         : int  NA NA NA NA NA NA NA NA NA NA ...
##  $ C7H8                        : num  NA NA NA NA NA NA NA NA NA NA ...
##  $ C6H6                        : num  NA NA NA NA NA NA NA NA NA NA ...
##  $ Ruido                       : int  NA NA NA NA NA NA NA NA NA NA ...
##  $ C8H10                       : num  NA NA NA NA NA NA NA NA NA NA ...
##  $ Temperatura                 : num  6.6 6.2 5.9 5.5 5.3 5.1 4.9 4.7 5.1 4.9 ...
##  $ Humedad.relativa            : int  89 89 90 90 89 88 87 87 83 85 ...
##  $ Presión                     : int  1019 1019 1019 1019 1018 1018 1018 1019 10
##  $ Radiación                   : int  0 0 0 0 0 0 0 0 11 45 ...
##  $ Precipitación               : num  0 0 0 0 0 0 0 0 0 0 ...
##  $ Velocidad.máxima.del.viento: num  3.2 4.2 4.1 4.1 3.8 4.5 2 3.1 4.6 2.3 ...
```

```
#La estructura del dataset cuenta con 449.026 observaciones y 27 variables.
#Observamos la columna Fecha correctamente convertida a tipo POSIXct.
```

3.4. Primera revisión de los valores perdidos

Calculamos número de valores ausentes por columna :

```
##colSums(is.na(datos)
nulos_por_columna <- sort(colSums(is.na(datos)),decreasing = TRUE)

#Mostramos el resultado en pantalla:
print(nulos_por_columna)
```

```
##                        C6H6                        C7H8
##                      402660                      402240
##                       C8H10                         NH3
##                      402087                      401307
##                       Ruido                         PM1
##                      397324                      374126
##                          CO                       PM2.5
##                      298277                      226614
##                        PM10                         SO2
##                      226609                      124888
##                          O3                          NO
```

```
##                      122897                      113588
##                         NOx                         NO2
##                      113587                       96232
##             Humedad.relativa                 Temperatura
##                       32027                       16827
##                   Radiación         Velocidad.del.viento
##                       16182                       15832
## Velocidad.máxima.del.viento               Precipitación
##                       15736                       14525
##                     Presión         Dirección.del.viento
##                       13753                       13442
##                       Fecha             Día.de.la.semana
##                           0                           0
##                  Día.del.mes                        Hora
##                           0                           0
##                     Estación
##                           0
```

Al analizar la integridad de los datos, lo primero que destaca es que las columnas clave como la fecha, la hora, la estación y el día de la semana no tienen ni un solo valor nulo, lo que nos asegura una estructura temporal completamente limpia y continua para trabajar.

En cuanto a las variables contaminantes se observa una clara diferencia en su disponibilidad,indicio claro de las limitaciones instrumentales, ya que las casetas meteorológicas más sencillas miden menos parámetros que las estaciones mejor equipadas:

- Por un lado, los contaminantes principales como el NO2, el PM10 y el O3, junto con las variables meteorológicas, muestran una cantidad de datos muy robusta y una disponibilidad alta, lo que nos da una base sólida para realizar un análisis estadístico
- Por otro lado, compuestos más específicos como el benceno C6H6, el tolueno C7H8, el xileno C8H10o el ruido presentan ausencias masivas con cientos de miles de datos perdidos.

Factor que hemos considerado a la hora de seleccionar las variables definitivas para nuestro estudio.

4. Acondicionamiento de los datos
5. Análisis de datos perdidos e imputación
6. Detección de valores atípicos
7. Análisis univariante
8. Análisis bivariante
9. Análisis temporal
10. Modelo predictivo
11. Discusión
12. Conclusiones finales

Appendix M

Appendix M.1

The appendix is an optional section that can contain details and data supplemental to the main text. For example, explanations of experimental details that would disrupt the flow of the main text, but nonetheless remain crucial to understanding and reproducing the research shown; figures of replicates for experiments of which representative data is shown in the main text can be added here if brief, or as Supplementary data. Mathematical proofs of results not central to the paper can be added as an appendix.

Appendix N

All appendix sections must be cited in the main text. In the appendixes, Figures, Tables, etc. should be labeled starting with 'A', e.g., Figure A1, Figure A2, etc.

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.